Project03 — 정찰 SITREP 보조관

YOLO 검출·추적 → 규칙 상태기계 → Event Log → Gemma 4 SITREP·음성 질의응답

과제 요구	이 프로젝트
객체 탐지	YOLO11n(TensorRT) 사람·물체 검출 + ultralytics 내장 추적
이벤트 감지	규칙 상태기계 → Event 4종
유저 음성 입력	키 `v` → 5초 녹음 → Whisper
음성 출력	Gemma 4 E2B SITREP·답변 → Piper 한국어 음성

구영탄 202431466 · 2026-11-08

역할 분리 — 판정은 규칙, 설명은 LLM

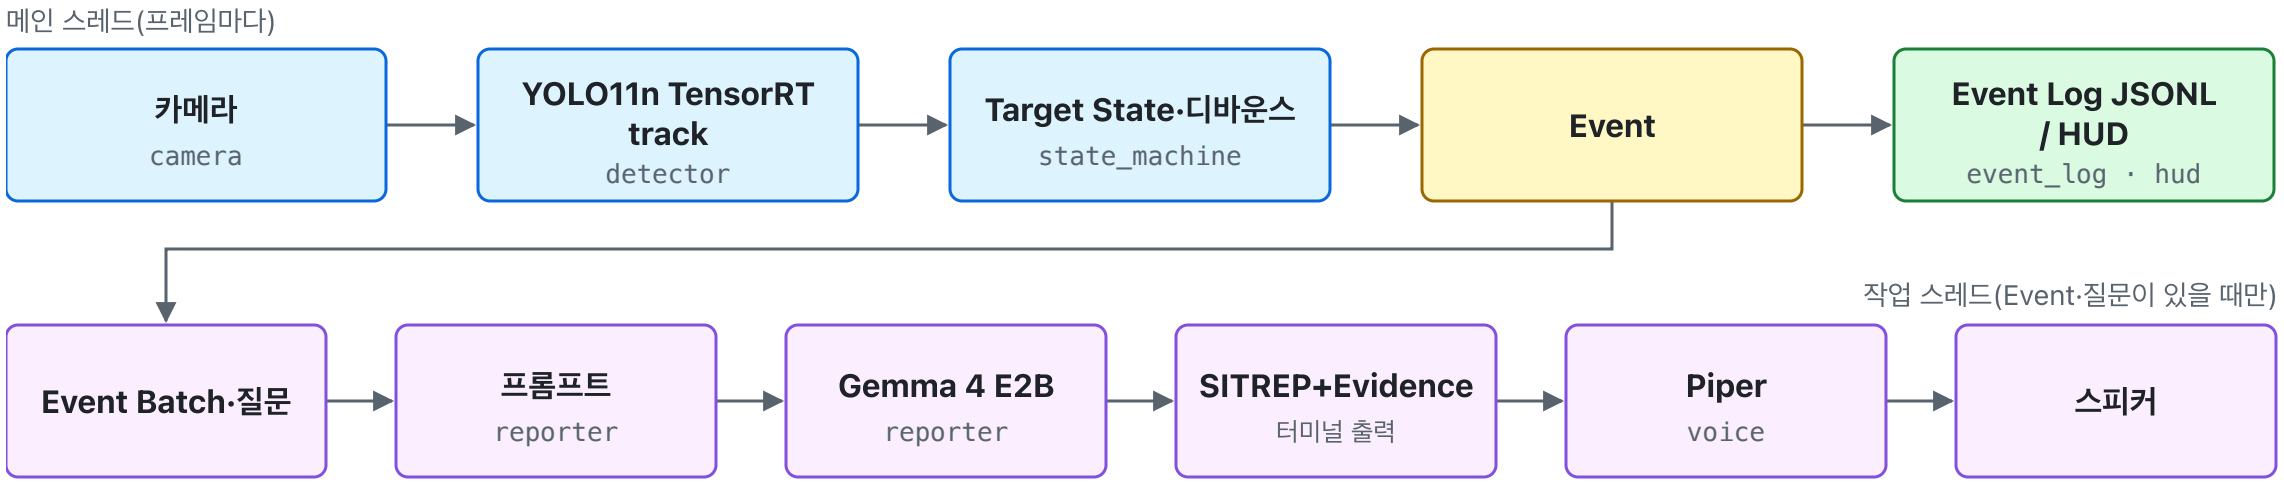
층	하는 일	성질
규칙 상태기계(`state_machine.py`)	Target State(Zone, Held Object) 판정, 바뀐 것만 Event로	결정론: 같은 입력 → 같은 Event 열
LLM(Gemma 4 E2B, `reporter.py`)	Event Log 텍스트로 SITREP·질의응답	이미지 입력 없음, 위험 판정 없음(ADR 0001)

왜 이렇게 나눴나

- 환각: SITREP 옆에 근거 Event 원문(**Evidence**)을 같이 출력 → 문장을 한 줄씩 대조 가능
- 재현성: 위험 여부를 LLM이 정하면 같은 장면에 다른 답이 나와 검증 불가
- 비용: Jetson 8GB 한 대에서 YOLO와 같이 돌려야 해서 매 프레임 LLM 호출·이미지 입력 불가

system 규칙(`COMMON_RULES`): 로그에 있는 사실만, 없으면 '관측되지 않음' / 한국어 낱말로만 / 위험 여부를 판정하지 마라 / 2~3문장

파이프라인 — 파일 11개, 두 줄의 흐름



메인 스레드(프레임마다): `camera` → `detector` (YOLO11n + 추적 id) → `state_machine` (`build_observations` → `step`) → `event_log` (메모리 목록 + `logs/events-YYYYMMDD-HHMMSS.jsonl`) + `hud` (박스·Target id·Zone·Held Object·FPS·Motion Level, 영어만) → 조립은 `main.process_frame`

작업 스레드(Event·질문이 있을 때만): `reporter` (Gemma 4 E2B, SITREP + Evidence 터미널 출력) → `voice` (Whisper STT / Piper TTS)

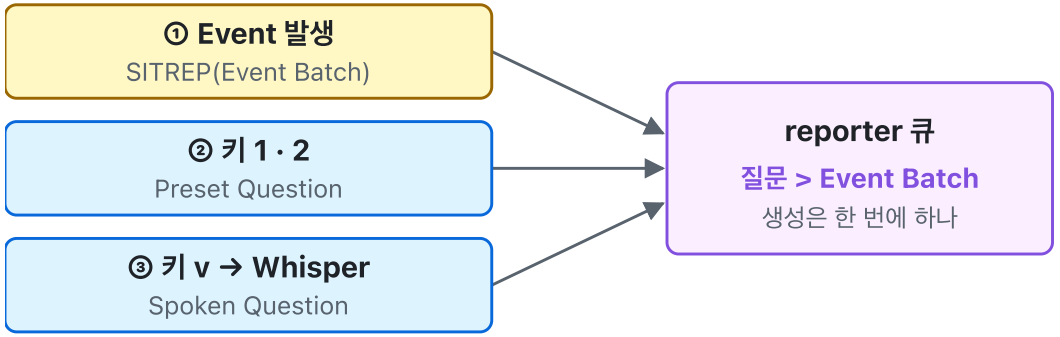
- 그 밖: `motion` (Motion Level), `platform_config` (트랙별 경로·명령), `bench` (측정표)
- 한 코드 두 트랙: 개발·테스트는 Mac 사본, 제출본은 Jetson 전용 카메라 파이프라인(`camera.JETSON_PIPELINE` , 읽기 제한 시간 `JETSON_READ_TIMEOUT_MILLISECONDS` 3초)

Event 4종과 LLM 트리거 3경로

Event	조건	임시값
`appeared`	보이는 상태가 T 동안 이어짐 → 확정 프레임의 Zone·물체를 담음	`DEBOUNCE_SECONDS` = 1.0
`gone`	Target이 T 동안 안 보임 → 마지막 Target State를 담고 삭제	같은 T
`zone_changed`	사람 박스 높이 / 프레임 높이 ≥ 기준이면 `near`, 아니면 `far`. 새 값이 T 유지	`NEAR_HEIGHT_RATIO` = 0.5
`object_changed`	물체 박스 중심이 사람 박스 안이면 보유. **물체 종류별로 따로** 디바운스	`HELD_OBJECT_CLASS_NAMES` 4종(knife·bottle·cell phone·backpack)

Event 필드는 `timestamp`, `target_id`, `kind`, `before`, `after` 다섯 개로 고정.

LLM이 불리는 경로는 셋뿐 (매 프레임·주기 호출 없음)



1. Event 발생 → SITREP(Event Batch + Snapshot)
2. 키 `1` (지난 1분 변화)· `2` (현재 상황) → Preset Question
3. 키 `v` → 5초 녹음 → Whisper → Spoken Question. 음량 RMS < 500(`SILENCE_RMS_THRESHOLD`)이면 Gemma를 부르지 않고 "질문을 듣지 못했습니다."

- 질문은 최근 60초(`QUESTION_WINDOW_SECONDS`) Event + Snapshot을 근거로 답
- 우선순위: 질문 > 대기 중인 Event Batch. 생성은 한 번에 하나, 생성 중 쌓인 Event는 다음 SITREP 한 번에

측정표 — Jetson Orin Nano 8GB

보드: L4T R36.5.2(11-07 업그레이드), torch 2.8.0 CUDA, TensorRT 10.3, cv2 4.8.0

항목	값
YOLO11n fp16 엔진 단독	54.2 ms/프레임(18.4 FPS)*
YOLO 동시 FPS·단독/동시 비율	**(3차 측정)**
Gemma 4 E2B 로드	74초
Gemma 생성	16.3 tok/s(첫 토큰 0.09s, 총 2.42s, 38토큰), YOLO 동시 실행 때도 16.3 tok/s
Gemma 첫 생성	5.7~8.5s → 시작할 때 워밍업 1회
RAM 최대(Gemma + YOLO 동시)	5377 / 7607 MB
Whisper base(CPU 빌드)	5초 wav에 7.3초
Piper 한국어 TTS	2회째 3.3초(그중 import 1.3초)
Event → SITREP 초	**(3차 측정)**
STT/TTS 동시 초	**(3차 측정)**
Motion Level NumPy/CuPy ms	**(3차 측정)**
앱 RAM	**(3차 측정)**
자동 테스트	unittest 49개(맥)

* 54.2 ms는 fp16 엔진, R36.4.7·100프레임 측정. 현재 기본 엔진은 int8(`platform_config.py` `YOLO_MODEL_PATH`)이며 int8 단독·동시 수치와 업그레이드 뒤 재측정은 (3차 측정).

시연

사용자 동작 순서(시연 리허설 순서 그대로)

1. 화면 밖 → 멀리서 들어온다 → `appeared`, SITREP 소리
2. 가까이 다가온다 → `zone_changed` far→near
3. 병(bottle)이나 휴대폰을 든다 → `object_changed`
4. 키 `1` → Preset Question(지난 1분)
5. 키 `v` → "지금 몇 명 있어?" 말하기 → Spoken Question, 답 음성
6. 소리 나는 중에 `v` 한 번 더 → 재생이 끊기고 녹음 시작
7. 물건 내려놓고 화면 밖으로 → `gone`
8. `q` → 종료

볼 것: 터미널의 Event 한 줄 → SITREP + Evidence + Snapshot, HUD의 `#id near bottle` 라벨, FPS·MOTION

HUD 캡처 — Jetson 실행 후

SITREP 터미널 캡처 — Jetson 실행 후

캡처: Jetson 실행 후 삽입

확장 — 판정 입력·보고 문구만 바꾸면 되는 후보

상태기계·Event Log·보고 층은 그대로 두고, 클래스 목록(`HELD_OBJECT_CLASS_NAMES`)·Zone 판정 함수(`judge_zone`)·이름표(`KOREAN_LABELS`)·프롬프트(`SITREP_SYSTEM_PROMPT`)만 바꾸면 되는 후보.

영역 기반 Zone(운전석·출입구)은 상수 조정으로는 안 되고, 지금의 높이 비율 `judge_zone` (`NEAR_HEIGHT_RATIO`)을 영역 판정으로 교체해야 한다.

후보	같은 구조를 다시 쓰는 방식	상태
S2 운전자 휴대폰	예: 클래스 목록을 `cell phone` (지금 `HELD_OBJECT_CLASS_NAMES` 에 있음)만 남기고 `judge_zone` 을 운전석 영역 판정으로 교체 → 기존 `zone_changed` (운전석 진입) + `object_changed` (휴대폰 듦) 조합으로 '운전 중 휴대폰 사용'을 보고	**후보로 검토, 미구현**
S6 자산 반출	예: 클래스 목록을 `laptop` 등 자산 클래스로 바꾸고(지금 목록에는 없음) `judge_zone` 을 출입구 영역 판정으로 교체 → 자산을 든 Target의 기존 `zone_changed` (출입구 쪽 이동)로 '자산이 출입구로 이동'을 보고	**후보로 검토, 미구현**

스트레치: Event가 날 때 크롭 1장을 mmproj로 Gemma에 넣어 텍스트 SITREP과 비교(미구현)

한계

- **카메라**: R36.5.2 업그레이드 뒤 1~2프레임 뒤 프레임 정지 — **진단 중, 11-08 갱신**. 그래서 YOLO 수치는 업그레이드 전 측정
- STT: Whisper `base` 체감 품질 "부족", `--prompt` 힌트(`WHISPER_PROMPT_HINT`) 효과 미측정
- TTS: Piper 호출마다 3.3초(그중 import 1.3초) — 문장마다 프로세스를 새로 띄움
- Gemma 첫 생성이 느려 워밍업 필요(시작 시간이 그만큼 늘어남)
- T보다 짧게 가려진 시간도 Target이 있던 시간으로 침 — 안 보이는 동안 Zone·Held Object는 그대로
- 임시값 미실측: `DEBOUNCE_SECONDS` , `NEAR_HEIGHT_RATIO` , `HELD_OBJECT_CLASS_NAMES` , `SILENCE_RMS_THRESHOLD` (말소리 RMS는 아직 안 잼)
- 질문 프롬프트는 최근 60초 Event를 상한 없이 넣음(SITREP만 `MAX_BATCH_EVENTS` 로 자름)
- 같은 추적 id로 다시 들어오면 `#1 gone` 다음 `#1 appeared` (번호 재부여 안 함)